

摘要

隨著人工智慧影像生成與換臉技術快速發展，Deepfake 人臉影像的製作門檻逐漸降低。此類影像若被用於社群平台、網路詐騙、假訊息傳播或身分冒用，可能影響個人隱私與資訊可信度。因此，本專題以人臉影像的 Deepfake 二元分類為研究主題，建立從資料整理、人臉偵測與裁切、模型訓練到結果評估的完整流程。

主訓練階段使用 HiDF 資料集，選取 2,500 張真實影像與 2,500 張偽造影像，共 5,000 張資料，並以 8:1:1 切分為訓練集、驗證集與測試集。影像先經 YOLO 人臉偵測與裁切，再調整為 224×224 像素，輸入 vit_base_patch16_224 進行 Real/Fake 分類。為使模型接觸不同於 HiDF 的拍攝條件與影像來源，後續另以 300 張自行蒐集資料進行 Retrain；其中 Real 類別以自行拍攝的手機照片為主，Fake 類別則蒐集自 X、Facebook 等公開網路平台。

實驗結果顯示，主訓練模型在 HiDF 獨立測試集的 Accuracy 為 90.42%，Macro F1 為 90.38%；Retrain 後模型在另一組 399 張獨立實際情境測試影像上的 Accuracy 為 85.96%，Weighted F1 為 86.04%。由於兩項結果使用不同來源的測試資料，本文僅分別說明各階段模型的測試表現，不將兩者視為直接的優劣比較。

關鍵字：Deepfake、人臉偵測、Vision Transformer、YOLO、Retrain

第一章 緒論

1.1 研究背景

近年生成式人工智慧快速發展，人臉替換與影像合成工具逐漸普及。部分 Deepfake 人臉影像已具有相當高的視覺真實度，僅依靠肉眼不一定能穩定辨識。當偽造影像在社群平台快速流通時，可能衍生假訊息、肖像濫用、身分冒用與詐騙等問題，因此 Deepfake 偵測已成為影像辨識與資訊安全領域的重要研究議題。

1.2 研究動機

本專題最初由實際應用需求出發，進一步將研究重點聚焦於模型訓練流程本身。公開資料集通常具有較一致的影像來源與處理方式，但實際手機照片與社群平台影像可能受到解析度、壓縮、亮度、色彩與裁切範圍影響。為觀察模型在不同影像來源下的表現，本專題先以 HiDF 完成主訓練，再以自行蒐集資料進行追加訓練。

1.3 研究目的

1. 建立 Real/Fake 人臉影像二元分類的資料處理與訓練流程。
2. 使用 YOLO 偵測並裁切主要人臉，降低背景資訊對分類的影響。
3. 使用 Vision Transformer 建立 Deepfake 人臉分類模型。
4. 以自行蒐集資料進行 Retrain，使模型接觸不同影像來源與拍攝條件。
5. 使用 Accuracy、Precision、Recall、F1-score 與混淆矩陣評估模型表現。

1.4 研究範圍與限制

本專題以單張、可清楚偵測到人臉的影像為主要研究範圍，分類目標為 Real 與 Fake。影片型 Deepfake、非人臉合成、重度美顏、濾鏡及大幅度修圖並非本研究的主要處理對象。模型表現亦可能受到資料來源、影像品質、人臉裁切範圍及類別分布影響。由於原始實驗資料後續遺失，本報告依據當時保留的模型測試結果與紀錄整理，無法重新執行完全相同的實驗以驗證再現性。

第二章 相關技術與資料集

2.1 Deepfake 人臉影像

Deepfake 通常指運用深度學習產生或修改影像、聲音與影片內容，使合成結果接近真實。本研究主要關注人臉換臉影像，即將來源人臉特徵轉移或融合至目標影像。此類影像可能在臉部紋理、五官邊界、光照一致性或局部融合區域留下特徵，但不同生成方法與壓縮處理會使可辨識線索產生差異。

2.2 YOLO 人臉偵測與裁切

YOLO 為單階段物件偵測模型，可同時預測目標類別與位置。本專題使用 YOLO-Face 模型找出影像中的人臉框，選取主要人臉後進行裁切。裁切結果再調整為分類模型需要的輸入尺寸，使 ViT 專注於人臉區域，並減少背景、衣物與場景資訊造成的干擾。

2.3 Vision Transformer

Vision Transformer (ViT) 先將影像分割成固定大小的 Patch，再將各 Patch 轉換為向量序列，透過 Self-Attention 學習不同影像區域之間的關聯。本專題採用

vit_base_patch16_224；輸入影像大小為 224×224，每個 Patch 大小為 16×16，並將原始分類頭替換為 Real/Fake 兩類輸出。

2.4 HiDF 資料集

HiDF 是以高擬真人臉偽造影像為目標建立的 Deepfake 資料集。本研究從中選取 2,500 張 Real 與 2,500 張 Fake 影像，維持 1:1 類別比例，作為主訓練階段的資料來源。HiDF 影像僅用於研究與模型訓練，未隨公開程式碼重新散布。

第三章 研究方法

3.1 整體研究流程

本研究流程可分為四個階段：資料整理、人臉前處理、模型訓練與模型評估。首先建立 Real/Fake 類別資料夾並完成資料切分；接著使用 YOLO 偵測人臉、裁切主要臉部並統一影像尺寸；其後以 ViT 進行主訓練，再載入主訓練權重，以自行蒐集資料進行 Retrain；最後分別在各自的獨立測試資料上計算分類指標與混淆矩陣。

階段	輸入	主要處理	輸出
資料整理	HiDF／自建影像	類別平衡與資料切分	Train／Validation／Test
人臉前處理	原始影像	YOLO 偵測、裁切、尺寸統一	人臉影像
模型訓練	人臉影像	ViT 主訓練與 Retrain	最佳模型權重
模型評估	獨立測試資料	分類預測與指標計算	報表與混淆矩陣

3.2 資料組成與切分

主訓練資料共 5,000 張，以 8:1:1 切分為訓練集、驗證集與測試集。Retrain 資料共 300 張，依最新版資料整理流程分為訓練集與驗證集，其中約 80% 用於追加訓練、20% 用於驗證。另有 399 張影像作為 Retrain 後模型的獨立測試資料；此測試資料不參與模型訓練與驗證。

階段	資料來源	用途	數量	切分方式
主訓練	HiDF	訓練、驗證、測試	5,000	8:1:1
Retrain	自行蒐集資料	追加訓練、驗證	300	約 80%/20%

階段	資料來源	用途	數量	切分方式
額外測試	實際情境影像	獨立測試	399	不參與訓練

自行蒐集資料中的 Real 類別以手機拍攝的原況照片為主；Fake 類別則由 X、Facebook 等公開網路平台蒐集。上述網路影像僅用於課程研究與模型測試，不在本專題公開儲存庫中重新散布。

3.3 影像前處理

每張影像先由 YOLO-Face 偵測人臉位置。若影像包含多張人臉，程式依設定選取主要人臉；若未偵測到有效人臉，則不納入後續分類。成功裁切後，影像調整為 224×224 ，轉換為 Tensor，並依預訓練模型需求進行正規化。

3.4 資料增強

訓練階段加入隨機裁切、水平翻轉、仿射變換、銳利度調整、ColorJitter 與白平衡等處理，以增加訓練影像的變化。這些方法的目的是在於降低模型對單一光線、色彩或裁切條件的依賴；本研究未另外進行消融實驗，因此不將資料增強描述為已被單獨證實能提升泛化能力。

第四章 模型訓練

4.1 主訓練設定

主訓練使用 ImageNet 預訓練的 vit_base_patch16_224，並將分類輸出調整為兩類。訓練過程以驗證集結果挑選最佳權重，最終儲存為 best_vit_model.pth。Epoch 保留當時實驗設定，其餘參數依最新版程式整理如下。

項目	設定	項目	設定
模型	vit_base_patch16_224	Epoch	30
Batch size	8	Image size	224×224
Learning rate	1×10^{-4}	Weight decay	0.01
Optimizer	AdamW	Loss	CrossEntropyLoss
Seed	42	輸出權重	best_vit_model.pth

4.2 Retrain 設定

Retrain 並非重新從隨機權重開始訓練，而是載入主訓練完成的 `best_vit_model.pth`，使用自行建立的 Real/Fake 人臉資料進行追加訓練。此階段的目的是在於讓模型進一步接觸不同於 HiDF 的影像來源與拍攝條件，並觀察模型在額外實際情境測試資料上的辨識表現。

項目	設定	項目	設定
基礎權重	<code>best_vit_model.pth</code>	Epoch	12
Batch size	8	Image size	224×224
Learning rate	3×10^{-5}	Weight decay	0.0001
Optimizer	AdamW	Loss	CrossEntropyLoss
輸出權重	<code>best_vit_model_retrain.pth</code>	資料用途	Train/Validation

第五章 實驗結果與分析

5.1 評估指標

本研究使用 Accuracy、Precision、Recall、F1-score 與混淆矩陣進行評估。Accuracy 表示全部測試影像中預測正確的比例；Precision 表示被模型判定為某類別的影像中實際屬於該類別的比例；Recall 表示某真實類別被正確找出的比例；F1-score 則為 Precision 與 Recall 的調和平均。

5.2 主訓練模型測試結果

類別	Precision	Recall	F1-score	Support
Fake	0.9591	0.8440	0.8979	250
Real	0.8612	0.9641	0.9098	251
Accuracy	—	—	0.9042	501
Macro avg	0.9102	0.9041	0.9038	501
Weighted avg	0.9101	0.9042	0.9038	501

真實類別／預測類別	預測 Fake	預測 Real
真實 Fake	211	39
真實 Real	9	242

主訓練模型在 501 張 HiDF 測試影像上的 Accuracy 為 90.42%。250 張 Fake 影像中有 211 張正確分類，Fake Recall 為 84.40%；251 張 Real 影像中有 242 張正確分類，Real Recall 為 96.41%。結果顯示模型在 HiDF 測試集對 Real 類別的辨識較穩定，但仍有 39 張 Fake 被誤判為 Real。

5.3 Retrain 後模型測試結果

類別	Precision	Recall	F1-score	Support
Fake	0.9042	0.8839	0.8939	267
Real	0.7754	0.8106	0.7926	132
Accuracy	—	—	0.8596	399
Macro avg	0.8398	0.8473	0.8433	399
Weighted avg	0.8616	0.8596	0.8604	399

真實類別／預測類別	預測 Fake	預測 Real
真實 Fake	236	31
真實 Real	25	107

Retrain 後模型在 399 張獨立實際情境測試影像上的 Accuracy 為 85.96%，Weighted F1 為 86.04%。267 張 Fake 影像中有 236 張正確分類，Fake F1-score 為 89.39%；132 張 Real 影像中有 107 張正確分類，Real F1-score 為 79.26%。結果顯示模型對 Fake 類別仍具有一定辨識能力，但部分 Real 影像可能因光線、壓縮、拍攝品質或裁切差異而被誤判為 Fake。

5.4 不同階段模型之結果整理

模型階段	測試資料	測試數量	Accuracy	Weighted F1
主訓練	HiDF 測試集	501	0.9042	0.9038
Retrain 後	額外實際情境資料	399	0.8596	0.8604

兩個模型使用的測試資料來源與類別分布不同，因此上述數值不能直接用來判定 Retrain 是否使模型表現提升或下降。主訓練結果反映模型在 HiDF 同來源測試集上的分類能力；Retrain 後結果則反映模型在另一組實際情境影像上的表現。若要嚴格驗證

Retrain 的效果，應將 Retrain 前後模型放在完全相同的獨立測試集上比較，但本研究因原始資料遺失，無法補做此項實驗。

第六章 討論

6.1 資料來源差異

公開資料集與網路、手機影像在解析度、色彩、壓縮與拍攝方式上可能存在差異。模型若主要從單一資料來源學習，可能同時學到該資料集特有的統計特徵，使同來源測試結果較高，但換到不同來源後表現下降。Retrain 的設計即是讓模型接觸額外影像來源，但現有實驗不足以單獨量化其改善幅度。

6.2 人臉裁切的影響

YOLO 人臉框的大小與位置會直接影響 ViT 的輸入內容。裁切過小可能遺失臉部邊界與融合區域；裁切過大則可能帶入背景與非臉部資訊。因此，即使是同一張圖片，不同裁切策略也可能造成分類結果差異。

6.3 實驗限制

6. 兩階段模型未使用同一組獨立測試集，因此不能直接證明 Retrain 的改善效果。
7. 額外測試資料的 Real/Fake 類別數量不平衡，Accuracy 需搭配各類別 F1-score 解讀。
8. 網路 Fake 影像來源較分散，生成方法與平台壓縮方式未完整標註。
9. 原始實驗資料遺失，無法重新執行完全相同的切分與訓練流程。
10. 研究範圍限於單張人臉影像，結果不能直接推論至影片型 Deepfake。

第七章 結論與未來方向

7.1 結論

本專題完成一套以 YOLO 人臉前處理與 Vision Transformer 分類為核心的 Deepfake 人臉影像訓練流程。主訓練模型在 HiDF 測試集取得 90.42% Accuracy；以自行蒐集資料 Retrain 後，模型在另一組 399 張實際情境影像上取得 85.96% Accuracy。研究結果顯示 ViT 能學習 Real/Fake 人臉影像的分類特徵，但模型表現仍受到資料來源、類別分布、影像品質與人臉裁切影響。

本研究的主要價值在於完成從資料集整理、人臉偵測與裁切、ViT 主訓練、追加訓練到獨立測試的完整實作。由於兩階段測試資料不同，本文不宣稱 Retrain 已直接提升泛化能力，而將其視為使模型接觸不同資料來源的一項實驗設計。

7.2 未來方向

11. 重新建立具完整來源紀錄與固定切分的資料集，以提高實驗可再現性。
12. 在同一獨立測試集上比較 Retrain 前後模型，量化追加訓練的實際效果。
13. 加入跨資料集測試，評估模型面對不同 Deepfake 生成方法時的泛化能力。
14. 進一步比較不同人臉框擴張比例與裁切策略對分類結果的影響。
15. 擴充至影片資料，納入時間序列與影格一致性資訊。

參考文獻

- [1] Kang, C., Jeong, S., Lee, J., Choi, D., Woo, S. S., & Han, J. (2025). HiDF: A Human-Indistinguishable Deepfake Dataset. Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining.
- [2] Dosovitskiy, A., et al. (2021). An Image is Worth 16×16 Words: Transformers for Image Recognition at Scale. International Conference on Learning Representations.
- [3] Ultralytics. YOLO Documentation. <https://docs.ultralytics.com/>
- [4] Hugging Face. PyTorch Image Models (timm). <https://github.com/huggingface/pytorch-image-models>
- [5] akanametov. YOLO-Face. <https://github.com/akanametov/yolo-face>